


1 Tijdens de analyse van een dataset moet jij, als data scientist, de volgende berekeningen doen:

1 pt. **a.** $\frac{\partial z}{\partial y}$ als $z(x, y) = \frac{1}{x} + 2x^2y^3$
Wat is $\frac{\partial z}{\partial y}$ als

1 pt. **b.** $f(x) = -\sin\left(\frac{x^2}{6}\right)$
Wat is $f'(x)$ als

2 In de figuur hieronder zie je de snelheid (m/s) van een fietser (V) op basis van de tijd (t). De snelheid kan gemodelleerd worden met $V = 0.25t$




2 pt. **a.** Wat is de afstand die de fietser heeft afgelegd na 12 seconden?

1 pt. **b.** Teken de bovenstaande figuur over en geef in je tekening aan wat je bij vraag a hebt berekend

3 Geef een reeks van 6 getallen waarvoor het gemiddelde 6 is, de mediaan 7 en de modus 1

4 pt.

- 4 Je werkt als data-analist bij een supermarktketen en onderzoekt welke producteigenschappen samenhangen met de Nutri-Score van producten. Nutri-Score is een voedselkeuzelog, het label kent een score toe van A (beste keuze) tot E (minst gezonde keuze).




Hieronder zie je een representatieve dataset van producten:

Product	Verzadigd vet (g)	Onverzadigd vet (g)	Eiwitten (g)	Koolhydraten (g)	Suikers (g)	Vezels (g)	Nutri-Score (A-E)
Brood	0.5	1.2	8	45	3	6	B
Kaas	18.0	10.0	25	2	0	0	D
Chocolade	20.0	5.0	5	50	43	2	E
Koffie	0.0	0.0	1	0	0	0	A
Frisdrank	0.0	0.0	0	30	28	0	D
Diepvriespizza	7.0	6.0	6	40	4	3	C

- 3 pt. a. Geef alle vier meetniveaus en geef daarbij aan welke kolommen tot welk meetniveau behoren
- 5 pt. b. Bereken de meest geschikte beschrijvende statistieken voor de kolom 'Eiwitten'. Onderbouw de keuzes die je maakt.

- 2 pt. **c.** We kijken nu specifiek naar de kolom 'suiker'. Hieronder zie je de verdeling van de kolom suiker, voor de hele dataset van producten.




Geef een schatting van het gemiddelde, de modus en de mediaan, op basis van de bovenstaande visualisatie en leg uit waarom.

- 1 pt. **d.** Beschrijf de verdeling van de kolom 'Suiker', op basis van de figuur bij vraag c. Gebruik hiervoor de geschikte termen uit de statistiek.
- 2 pt. **e.** Stel dat we de Nutri-Score willen voorspellen op basis van de producteigenschappen. Geef voor de onderstaande methoden aan of je deze zou kunnen gebruiken om de Nutri-score te voorspellen en waarom.
- 1) Pearson's r
 - 2) Spearman ρ
 - 3) Enkelvoudige lineaire regressie
 - 4) Multipele lineaire regressie
 - 5) Logistic regression
 - 6) One vs. Rest logistic regression

- 5 Je werkt als data-analist bij het Preventief Asset & Structureel Constructie-Analyse Laboratorium, een organisatie die zich richt op het voorspellen van onderhoudsintervallen voor gebouwen en infrastructuur. Het doel is om te bepalen wanneer onderhoud nodig is om dure reparaties te voorkomen en de levensduur van gebouwen te verlengen. We hiervoor een lineair regressiemodel dat "aantal jaren tot onderhoud" voorspelt op basis van verschillende kenmerken van een gebouw.

Je begint met een Exploratory Data Analysis (EDA), waarin je gaat onderzoeken wat de relatie is tussen de verschillende variabelen. Je maakt daarom een heatmap en krijgt het volgende resultaat:



- 1 pt. a. Interpreteer deze heatmap en geef aan wat voor consequenties de resultaten hebben op het modelleren
- 2 pt. b. Voor de correlatiecoëfficiënten in de heatmap wordt standaard de Pearson's r gebruikt. Is dit de juiste methode? Beargumenteer je antwoord.

Je besluit een model te trainen, hieruit volgen de coëfficiënten:

De coëfficiënt voor het bouwjaar (in jaren vanaf 1900) is: -0,08

De coëfficiënt voor de materiaalconditie (schaal van 1 tot 10, waarbij 10 uitstekend is) is: 1,2

De coëfficiënt voor het aantal gebruikers per dag is: -0,003

Snijpunt met de "Jaren tot onderhoud"-as: 15

- 4 pt. **c.** Een van de gebouwen is het InnovatieCentrum Den Haag, gebouwd in 1995, met een materiaalconditie van 7 en 3.500 gebruikers per dag. Wat is volgens het model het jaartal wanneer de volgende onderhoudsbeurt zou moet plaatsvinden? Ga ervan uit dat we nu in het jaar 2025 leven.
- 1 pt. **d.** Het model heeft een R^2 (R-squared) van 0.74. Jouw collega geeft aan dat het betekent dat 74% van de voorspellingen van het model correct zijn. Ben jij het eens met deze collega? Beargumenteer waarom wel/niet.